

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ
ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«САМАРСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ ИМЕНИ АКАДЕМИКА С. П. КОРОЛЕВА
«САМАРСКИЙ УНИВЕРСИТЕТ»

Институт информатики и кибернетики
Кафедра геоинформатики и информационной безопасности

Отчёт по лабораторной работе №4
«Параллельное программирование»

Выполнил:
Бисултанов Умар
Группа 6312

Самара - 2026

Цель работы

Освоить технологию CUDA и реализовать параллельный алгоритм умножения матриц на GPU. Провести экспериментальные исследования зависимости времени выполнения от размера матриц и конфигурации блоков.

Постановка задачи

Модифицировать последовательную программу умножения матриц для выполнения на графическом процессоре с использованием CUDA. Исследовать влияние параметров сетки и блоков на производительность.

Описание алгоритма

Каждый поток CUDA вычисляет один элемент результирующей матрицы. Сетка потоков организована в виде двумерной структуры. Блоки также имеют двумерную конфигурацию.

Основные этапы:

1. Копирование данных на GPU
2. Запуск CUDA-ядра
3. Вычисление элементов матрицы
4. Копирование результата обратно на CPU

Параметры экспериментов

Размеры матриц: 200, 400, 800, 1200, 1600, 2000.

Конфигурации блоков: 8x8, 16x16, 32x32.

Результаты экспериментов (время, сек)

N	CPU	8×8	16×16	32×32
200	0.30	0.06	0.04	0.05
400	2.40	0.25	0.15	0.18
800	19.5	2.00	1.20	1.40
1200	65.0	6.50	3.80	4.50
1600	155	14.0	8.20	9.50
2000	310	26.0	15.5	18.0

Таблица 1. Разные конфигурации сетки блоков с разными размерами матриц

N	8×8	16×16	32×32
200	5.0	7.5	6.0
400	9.6	16.0	13.3
800	9.7	16.3	13.9
1200	10.0	17.1	14.4
1600	11.1	18.9	16.3
2000	11.9	20.0	17.2

Таблица 2. Ускорение GPU vs CPU: $S = \frac{T_{CPU}}{T_{GPU}}$

Графики




Рисунок 1 - Зависимость времени от размера матрицы




Рисунок 2 - Зависимость коэффициента ускорения от размера матрицы

Анализ результатов

Использование GPU значительно ускоряет вычисления. Наиболее эффективной оказалась конфигурация блоков 16x16. Слишком маленькие блоки приводят к недозагрузке GPU, а слишком большие — к снижению эффективности из-за ограничений ресурсов.

Выводы

В ходе лабораторной работы был реализован параллельный алгоритм умножения матриц с использованием технологии CUDA и проведены эксперименты с различными размерами матриц и конфигурациями блоков потоков. Результаты показали, что при увеличении размера матрицы время выполнения на CPU возрастает в соответствии с кубической сложностью алгоритма, тогда как использование GPU позволяет значительно сократить время вычислений за счёт параллельной обработки. Установлено, что наилучшие показатели достигаются при размере блока 16×16, обеспечивающем оптимальное использование ресурсов GPU, в то время как меньшие и большие размеры блоков приводят к снижению эффективности. Также наблюдается рост ускорения с увеличением размера задачи, достигающий порядка 15–20 раз, что подтверждает эффективность применения CUDA для вычислительно сложных задач.